

Observatório de Ações — Tecnologias, Arquitetura e Melhorias

Oct 1, 2026 · @Renato Nati

Quinze testes, três aprovados. O mais forte não é o que o projeto foi feito para prever: **volatilidade mede IC 0,303 contra 0,081 da direção** — 3,7 vezes mais sinal. A direção leva a previsão de 50,8 para 52,6 acertos em 100, e implementar tudo que resta acrescenta 0,3. O canal de **notícias**, coração do TCC original, segue **não medido** — é a única incógnita grande, e fechá-la custa R\$ 39. Nada aqui atravessa a barreira de custo de transação da pessoa física.

O balanço

Tudo que foi testado neste projeto, com o número que decidi. Quinze testes: **três passaram**, doze reprovaram.

Passou

Sinal	Medida	Ressalva
Persistência de volatilidade	IC 0,303 contínuo · t = +11,34	O único forte. Protocolo estrito dá AUC 0,551 e reprova na porta por skill de Brier +0,005
Exposição cambial → gap de abertura	IC -0,081 · t = -3,81 (Fama-MacBeth)	Reversão. Vive no leilão de abertura, a janela de maior spread
Payroll EUA	p = 0,000 · controle p = 0,020	Contemporâneo : explica o dia, não o prevê

Reprovou

Teste	Número	Veredito
Lead-lag entre papéis (306 pares)	razão observado/nula = 1,021	Acaso. O "melhor" par foi celulose prevendo drogaria
Meta-labeling	t = 1,53 · AUC 0,517 · não monótono	Ganho de +4,6 p.p. cabe no ruído

Teste	Número	Veredito
Surpresa IPCA	p = 0,508 (131 divulgações)	
Surpresa IGP-M	p = 0,788 (132)	
Surpresa desocupação	p = 0,750 (60)	Viés de $-0,90\sigma$ — consenso superestima
Surpresa câmbio	p = 0,447 (129)	Surpresa ~ 0 por construção: consenso medido tarde demais
CPI EUA	p = 0,689	
PMI China	p = 0,087	Marginal
Energia como driver	t = +0,83 (Fama-MacBeth)	Passava no teste ingênuo; morreu no rigoroso
Metais (minério, cobre, ouro)	IC -0,004	
Os 14 drivers juntos	IC -0,002 contra -0,081 de 4	Mais drivers dão pior
Momento 12-1	t = +0,74	10 papéis é amostra pequena demais
Reversão 1 mês / 1 dia	t = +0,19 / -1,07	

Nunca medido

Canal	Por quê
Notícias	O coração do TCC. 5 scores no banco — sem eventos para medir
PEAD (surpresa de lucro)	Consenso de analistas por empresa não é gratuito no Brasil

A lição que atravessa os quinze

Todo IC animador veio de contaminação de horizonte ou de erro-padrão inflado. Brent a 0,19 era barra de 24h englobando o pregão. Energia "significativa" era erro-padrão tratando pares (papel, dia) como independentes. O meta-labeling a +4,6 p.p. era ruído sem monotonia.

E o mais perigoso de todos: os betas de surpresa com 19 divulgações desenhavam a história economicamente perfeita — MGLU3 na ponta negativa por ser varejo alavancado. Com 131, o ranking inteiro se reorganiza. **Um resultado que confirma a intuição é o mais difícil de duvidar.**

Tecnologias

Das onze peças do TCC de 2013, cinco estão reconstruídas e medidas, quatro existem em versão parcial e duas não foram feitas. A rotulagem ficou melhor do que o plano: o mercado rotula sozinho.

Componente (2013)	Equivalente 2026	O que existe hoje	Estado
FireTwitter (Twitter dos jornais)	GDELT 2.0 + RSS + CC-NEWS + CVM/RAD	<code>obs/ingest.py</code> : GDELT + parser RSS/Atom em stdlib. Só título, sem corpo. Sem CC-NEWS, sem CVM	Parcial
SimilarWeb (popularidade do jornal)	Aprender o peso de cada veículo pelos dados	Pesos escritos à mão em <code>config/sources.yml</code> . O <code>fit-source-weights</code> é só uma linha de README	Não feito
Tradutor Google/Microsoft	Eliminar via embeddings multilíngues	Etapa eliminada, mas por casamento lexical normalizado — não por embeddings	Parcial
LingPipe (classificador econômico)	Encoder fine-tunado, rotulagem por LLM	<code>entity.relevance()</code> : heurística com vocabulário de mercado e de ruído. Pegou o falso positivo "Vale → matéria sobre bots"	Feito
Polaridade de sentimento	FinBERT-PT-BR como baseline	<code>score_lexicon</code> : léxico PT+EN, negação, desconto de rumor, 11 tipos de evento. Sem FinBERT. <code>score_llm</code> é um gancho vazio	Parcial
Similaridade → popularidade	pgvector/Qdrant + HDBSCAN	SimHash 63 bits + Jaccard + impressão digital numérica . Agrupou corretamente o par real de JCP do Bradesco	Feito

Componente (2013)	Equivalente 2026	O que existe hoje	Estado
DBpedia + SPARQL	Wikidata + OpenFIGI + GLEIF	Alias com código de papel sensível a caixa + lista de ambíguos. Aliases ainda manuais	Parcial
Grafos de países (Gephi)	Propagação por cadeia de fornecedores	Substituído por algo melhor: <code>obs/drivers.py</code> , exposição a 14 drivers macro	Feito
Árvore sintática Stanford	Cortar	Cortado	Feito
CorpusFactory (rotulagem manual)	LLM rotulador + adjudicação humana	<code>obs/label.py</code> : rotulagem automática pelo retorno anormal realizado . Nem manual nem LLM	Feito
Cadeias de Markov	Detector de regime	Nada construído	Não feito

O que não existia em 2013


Peça	O que existe
Calibração	PAVA isotônica + Platt, escritos à mão. Platt venceu fora da amostra em 10 de 12 dobras
Validação	Walk-forward com embargo, IC, skill de Brier, decis, Fama-MacBeth. Sem acurácia, de propósito
Cadeia de afetação	14 drivers (câmbio, metais, energia, agro, índices), regressão múltipla com ridge
Alarmes	4 portas + cooldown, 8 casos testados um a um
Painel	<code>http.server</code> stdlib, dois visores com taxa-base marcada na barra
Análise de poder	Com 10 papéis e 1 ano: 22% de chance de detectar IC de 0,03

O protótipo inteiro depende de `requests`, `numpy` e `pyyaml`. Servidor web, banco, parser de RSS, clusterização e regressão isotônica são stdlib ou escritos à mão.

Arquitetura

A cadeia de afetação roteia as notícias — não prevê o preço

Canal de preço: IC 0,081 medido · Canal de notícias: nunca medido



arquitetura · 8 componentes, 1 laço de roteamento

A seta em destaque é a mudança de desenho: a cadeia de afetação não entra como preditor de preço, e sim como **roteador** — ela diz ao sistema de notícias o que procurar para cada papel.

Hoje um papel só reage a matéria que escreve o nome dele, e por isso há apenas 23 scores em 156 artigos. Com o roteamento, PETR4 e PRIO3 passam a escutar OPEP e estoques americanos; CSNA3 escuta minério e China; os bancos escutam dólar e risco global.

As duas linhas que chegam ao sinal agregado são independentes: o canal de preço já está medido em IC 0,081, o canal de texto nunca foi medido contra retorno realizado.

O que foi medido

Só a exposição cambial sobrevive ao teste rigoroso. Energia e metais passam no teste ingênuo e reprovam quando os erros-padrão são agrupados por dia.

Sinal	Alvo	IC	Significância	Veredito
Exposição cambial (DXY, USDBRL, EURUSD, USDCNY)	Resíduo transversal do gap T+1	-0,081	t = -3,81 (Fama-MacBeth)	Vale
HSI → gap do mesmo dia	Resíduo transversal do gap	+0,025	n = 7.506	Vale, fraco
Energia (Brent, gás)	Resíduo transversal do gap T+1	+0,054 agrupado	t = +0,83	Reprovado
Metais (minério, cobre, ouro)	Resíduo transversal T+1	-0,004	—	Nada
Todos os 14 drivers juntos	Resíduo transversal T+1	-0,002	—	Diluição
Lead-lag entre ações (306 pares)	Resíduo T+1	razão observado/nula = 1,021	—	Refutado
Canal de notícias	—	nunca medido	—	Em aberto

Três lições das medições

Mais drivers deu pior. Catorze parâmetros com 250 observações diluem o sinal. O conjunto completo (-0,002) é pior que câmbio sozinho (-0,081). Isso é um limite de desenho, não de implementação.

O erro-padrão ingênuo mente. Tratar 4.734 pares (ação, dia) como independentes infla a significância: 18 ações no mesmo dia compartilham o mesmo choque macro mesmo depois de removida a média transversal. Com Fama-MacBeth, energia cai de "significativo" para t = 0,83.

Lead-lag entre papéis por correlação bruta não existe. Com 306 pares testados, 4,2% passaram o limiar — exatamente o que o acaso prevê. O "melhor" par foi celulose prevendo drogaria com IC de 0,127, cinco vezes o sinal real. Sem a hipótese nula por permutação, isso viraria uma estratégia.

Convertendo para probabilidade

	IC	Acertos em 100	P(alta top 10%)
Antes da cadeia de drivers	0,025	50,8	34,7%
Com exposição cambial	0,081	52,6	38,5%

Taxa-base de alta anormal: 33%. No top 1% do sinal, P(alta) chega a 41,5%.

A barreira que não se move

Vantagem esperada por operação: $IC \times \text{desvio do resíduo} \approx \mathbf{6 \text{ pontos-base}}$. Custo de ida e volta na B3 como pessoa física: **10 a 20 pontos-base**. O efeito vive no leilão de abertura, que é a janela de maior spread do pregão, e some até o fechamento.

Triplidar o IC não atravessou essa barreira, e nenhuma melhoria da seção seguinte atravessa.

As anomalias famosas, testadas aqui

A literatura de finanças tem crise de replicação documentada: Hou, Xue & Zhang testaram ~450 anomalias publicadas e a maioria falhou sob protocolo uniforme; McLean & Pontiff mostraram queda de ~58% nos retornos após a publicação; Harvey e coautores defendem limiar de $t \approx 3,0$ pelo volume de testes da área.

Em vez de citar, medimos nos 10 anos de B3 do próprio projeto:

Sinal famoso	Alvo	IC médio	t
Momento 12-1	retorno 21 pregões	+0,0145	+0,74
Reversão 1 mês	retorno 21 pregões	+0,0035	+0,19
Reversão 1 dia	retorno 21 pregões	-0,0186	-1,07
Baixa volatilidade	retorno 21 pregões	-0,0403	-2,16
Persistência de volatilidade	retorno amanhã	+0,1836	+11,34

Três ressalvas sobre essa tabela

A baixa volatilidade saiu com sinal invertido. O sinal foi definido como **-vol** (a anomalia diz: menos volátil → mais retorno). O IC negativo significa que **mais** volatilidade passada previu **mais** retorno futuro — o oposto do publicado.

Os t de 21 pregões estão inflados. A janela avança de 5 em 5 dias com horizonte de 21, então há ~4× de sobreposição entre observações consecutivas, o que subestima o erro-padrão. O -2,16 da baixa vol provavelmente não sobrevive à correção. **O teste de volatilidade não tem esse problema** — horizonte de 1 dia, passo de 5, sem sobreposição.

Momento falhar aqui não refuta momento. Dez blue chips é amostra pequena demais para anomalia transversal; o teste clássico usa centenas de papéis. O resultado diz "não detectável aqui", não "não existe".

A exceção não testável

PEAD — deriva pós-anúncio de resultados — é, pela literatura, o efeito ligado a **direção** com melhor histórico de replicação, documentado desde Bernard & Thomas nos anos 80. Não foi possível testar: exige consenso de lucro por empresa, que é o item bloqueado do projeto.

Mais uma convergência: era o canal apontado como mais valioso desde a primeira resposta, e é o único ligado a direção com credencial comparável à da volatilidade.

As telas

Duas telas, servidas pelo próprio `obs/api.py` em `http.server` da stdlib.

Tela	O que tem
<code>web/index.html</code>	Três destaques (sinal mais positivo, mais negativo, maior agitação), tabela com filtros por setor, busca, favoritos, nove ordenações, exportar CSV, navegação por teclado, modal de ajuda, pílula de progresso até calibrar
<code>web/acao.html</code>	Gráfico de preço com notícias sobrepostas (cor = direção do texto, tamanho = peso), lista ordenável, e a coluna " pregão seguinte " confrontando o que o texto sugeria com o que o preço fez

A disciplina que as telas aplicam

Coluna não calibrada é ocultada, não preenchida com número inventado. A pílula de status mostra `0/120` — o progresso até haver eventos rotulados suficientes.

Todo selo de qualidade vem de `obs/medidas.py`, que é a **única fonte** desses números: o HTML não tem métrica escrita à mão. Mudou uma medição, muda lá, citando o script que a produziu.

Uma incoerência encontrada e corrigida

A tela escondia alta e queda por não estarem calibradas, mas exibia **86%** de agitação para MGLU3 — com `vol_calib = 0` no dado. Pior: aquele valor vinha de uma fórmula provisória, não do modelo ajustado que mediu o AUC.

Resolvido com o calibrador de verdade (`obs.volatility.fit_calibrator`), que tem porta de aceite própria — e que **reprovou**, mantendo a agitação em faixa ordinal.

O que foi acrescentado depois

- `GET /api/surpresas` — evento macro mais recente e o impacto implicado por papel
- Bloco **surpresa** em `GET /api/ticker/{tk}` — sensibilidade daquele papel aos quatro indicadores
- Cartão **Surpresa macro** no painel, com ranking de **Impacto implicado por papel**
- Seção **Sensibilidade a surpresa macro** no detalhe e em `acao.html`
- `GET /api/externos` — estado da camada estrangeira

Todos carregam **Não validada** com o motivo e a evidência de instabilidade.

As três cabeças

O sistema passou a ter três saídas sobre **um único pipeline**. Ingestão, relevância, cluster, novidade, score e agregação não mudaram; as cabeças leem as mesmas features.

Cabeça	Pergunta	Sinal medido	Estado
Alta	P(retorno anormal positivo em D+1)	IC 0,081	funciona
Queda	P(retorno anormal negativo em D+1)	IC 0,081	funciona
Agitação	P(amanhã no top 20% de volatilidade)	AUC 0,683	funciona
Confiança (meta-label)	P(a direção estar certa)	AUC 0,517	reprovada

A cabeça de volatilidade entrega 3,7x mais sinal

Formulação do alvo	Resultado
Contínuo (prever a magnitude)	IC +0,303

Formulação do alvo	Resultado
Binário na mediana	AUC 0,637
Top 20% de agitação	AUC 0,683
Top 10% de agitação	AUC 0,743

IC de 0,303 contra 0,081 da direção. Volatilidade é persistente — dia agitado tende a ser seguido de dia agitado — e isso a torna muito mais previsível. A cabeça **não diz a direção**: diz que vai mexer.

Duas medições minhas foram invalidadas até chegar nesses números: janela de features parando em T-1 enquanto o alvo era T+1 (AUC 0,518), e corte na mediana, que é o pior alvo possível porque a mediana é onde a distinção é ruído.

O mesmo teste também imprimiu "acerto 84,3%" no top 10%. **Esse número é inflado** pelo desbalanceamento de classes — com taxa-base de 12%, acerta-se muito só dizendo "não". AUC 0,743 é a métrica honesta.

O meta-labeling foi construído e reprovado

A ideia: um modelo dá a direção, outro estima se vale agir, e você opera só quando o segundo confia. Troca frequência por precisão — o único regime em que custo de transação é sobrevivível.

Limiar	Opera em	Acerto	Ganho	t
sem filtro	4.200	52,5%	—	—
0,54	737	53,9%	+1,3%	0,72
0,56	264	57,2%	+4,6%	1,53
0,58	97	55,7%	+3,1%	0,62

O melhor **t** é 1,53, abaixo de 2. E a sequência **não é monótona**: 57,2% → 55,7% → 56,0%. Se o meta discriminasse, o acerto subiria junto com o limiar. AUC de 0,517 confirma que ele quase não separa.

O ganho aparente de +4,6 pontos cabe no ruído. A porta ficou **desligada** (`metabel.ATIVO = False`): um filtro que não discrimina só reduziria a amostra sem ganho, e dar poder de veto a ele seria pior que não tê-lo.

Não tentei outros conjuntos de features de propósito — com seis tentativas se acha um que "funciona" por acaso. Ligar a porta exige refazer o teste e obter **t > 2 com** monotonia.

Um bloqueio removido

O brapi tem cota por janela e não cobria a watchlist. O Yahoo foi adicionado como fonte de preços: **4.986 cotações, 2 anos, 10 papéis**, sem chave. É o que destrava a calibração da cabeça de direção, gargalo desde o início.

A camada de surpresa

Evento agendado é estruturalmente diferente de tudo que medimos antes. Todo sinal anterior morreu por chegar tarde (GDELT com 15 min) ou por viver onde é caro capturar (leilão de abertura). Agendado não tem nenhum dos dois: **a data é publicada com antecedência e existe consenso**, então a surpresa é calculada em vez de inferida de texto.

$$\text{surpresa} = \frac{\text{realizado} - \text{mediana}_{\{\text{Focus}\}}}{\text{desvio das projeções}}$$

O desvio é essencial: 0,1 p.p. acima do consenso é enorme quando 146 economistas concordavam e irrelevante quando discordavam.

Funciona, com dado oficial e gratuito

131 surpresas do IPCA, de 10/2015 a 08/2026. Média -0,00 (consenso não enviesado) e desvio 1,20 — exatamente o que uma surpresa normalizada deve ter. Fontes: Focus via OData do BCB e realizado via SGS, ambas sem chave.

Mês	Consenso	Desvio	Realizado	Surpresa
06/2026	+0,32	0,05	+0,16	-3,44σ
02/2026	+0,47	0,10	+0,70	+2,36σ
03/2026	+0,50	0,18	+0,88	+2,11σ
05/2025	+0,39	0,05	+0,26	-2,54σ

Mas a parte transversal foi reprovada — duas vezes

Sozinha, surpresa macro move o **fator comum**, e o resíduo transversal remove o fator comum por construção. O que a tornaria útil é cada papel reagir **diferente**. Os betas estimados pareciam perfeitos:

Papel	Beta	Leitura econômica
VALE3	+0,00204	exportadora, receita em dólar
ABEV3	+0,00181	poder de preço
ITUB4	-0,00079	banco
BBDC4	-0,00225	banco
MGLU3	-0,00406	varejo doméstico alavancado

MGLU3 na ponta negativa e VALE3 na positiva é exatamente o que a teoria prevê, e ninguém contou isso ao sistema. **E não se sustenta.**

Amostra	Dispersão observada	Nula	p
19 divulgações	0,00182	0,00293	0,908
131 divulgações, 10 anos de preço	0,00130	0,00134	0,508

Sete vezes mais dados e o p mal se move. Não é falta de amostra.

Um resultado que confirma a intuição é o mais perigoso de todos, porque é o mais difícil de duvidar. Se eu tivesse parado na tabela de betas, você teria uma camada inteira construída sobre coincidência.

O suspeito foi testado e descartado

A data de divulgação é aproximada — dia 10 rolado para dia útil. Se o erro de data estivesse borrando o estudo de evento, uma **janela mais larga** recuperaria o efeito. Nenhuma chegou perto:

Janela	p
[0]	0,482
[0, +1]	0,555
[0, +2]	0,544
[-1, +1]	0,567
[-1, +2]	0,665

A data não era a causa.

Os betas se reorganizam quando a amostra cresce

A evidência mais direta de que são ruído:


Papel	Beta com 19 divulgações	Beta com 131
MGLU3	-0,00406 (o mais negativo)	-0,00009 (quase zero)
BBAS3	+0,00074	+0,00288 (o mais positivo)
SUZB3	+0,00019	-0,00212 (o mais negativo)

A leitura economicamente perfeita — MGLU3 na ponta negativa por ser varejo alavancado — era artefato de 19 observações. Com 131, o ranking inteiro troca de ordem.

Como a camada funciona

Surpresa macro vira sinal por papel — e a porta fica fechada

Quatro indicadores, 452 divulgações, 10 papéis · nenhum passou no teste



Teste de permutação

IPCA	131 · p 0,51
IGP-M	132 · p 0,79
Desocupação	60 · p 0,75
Câmbio	129 · p 0,45

precisa $p < 0,05$
nenhum chega perto

Pendente

PIB: Focus em %, série
SGS em índice encadeado
Câmbio: consenso medido
tarde demais, surpresa ~0

camada de surpresa · 4 indicadores, 452 divulgações, porta fechada

O caminho do dado é o mesmo para qualquer indicador: o **Focus** dá o consenso com sua dispersão, o **SGS** dá o realizado, e a surpresa normalizada divide a diferença pelo desvio das projeções. O beta de cada papel sai da regressão do retorno anormal no dia da divulgação, e o impacto implicado é $\text{beta} \times \text{surpresa}$ demeiado na watchlist.

Não é só IPCA. São quatro indicadores mensais com 452 divulgações somadas — e **os quatro reprovam** no teste de permutação, com p entre 0,45 e 0,79.

A integração macro → ação específica

Construída e visível nas duas telas, rotulada pelo que é:

- `GET /api/surpresas` — o evento mais recente e o impacto implicado por papel
- `GET /api/ticker/{tk}` ganhou um bloco `surpresa` com a sensibilidade daquele papel
- No painel: cartão **Surpresa macro** com ranking de **Impacto implicado por papel**
- No detalhe e em `acao.html` : **Sensibilidade a surpresa macro** do papel aberto

Exemplo real: o IPCA de 08/2026 veio **1,00σ abaixo** do consenso; SUZB3 recebe +0,21 p.p. implicado e BBAS3 -0,29 p.p.

Todo bloco carrega **Não validada** com o motivo e a evidência de instabilidade. Nenhum desses números entra em probabilidade: `ATIVO = False`.

Indicadores estrangeiros — e o primeiro efeito real da investigação

Não há Focus para fora do Brasil: o FRED exige chave e o World Bank só tem dado anual. Sem consenso, a fórmula da surpresa não existe.

A saída é método padrão em macro-finanças: no dia de uma divulgação agendada, o **movimento do instrumento mais sensível já é a surpresa**. Se o payroll sai em linha, o dólar não se mexe.

Evento	Instrumento	n	p (permutação)
CPI EUA	DXY	112	0,689
Payroll EUA	DXY	116	0,000
PMI China	HSI	117	0,087

O Payroll passa — dispersão 0,00362 contra nula de 0,00149, mais que o dobro. Primeiro canal de surpresa macro a passar em toda a investigação.

E não é circularidade

A proxy é o movimento do dólar, e a cadeia de afetação já regride contra o dólar todo dia — então o resultado podia ser só exposição cambial comum. O controle compara dias de payroll com dias sorteados:

	Dispersão
Dias de payroll (120)	0,00362
Dias aleatórios (média)	0,00218
Dias aleatórios (p95)	0,00337
p contra dias comuns	0,020

Em dia de payroll a sensibilidade ao dólar é genuinamente mais dispersa entre os papéis.

Mas explica, não prevê — e por isso fica desligada

A proxy é o movimento do dólar **no mesmo dia** do retorno da ação. Para aplicar o beta seria preciso conhecer esse movimento, que chega junto com o movimento da ação.

Serve para **atribuição** — *“o papel caiu porque é exposto ao dólar e hoje teve payroll”* — nunca para previsão. Torná-la preditiva exigiria o consenso publicado **antes** da divulgação, que é exatamente o que não existe de graça para indicadores estrangeiros.

`obs/externo.py` com `ATIVO = False` e `GET /api/externos` expondo o estado.

Uma discrepância de medição corrigida

O calibrador da cabeça de volatilidade foi rodado e **reprovado pela própria porta**: AUC 0,551 (mínimo 0,55) mas skill de Brier +0,005 (mínimo +0,01).

Isso expôs que o **AUC 0,683 não se reproduz** sob o protocolo estrito. A medição original usava divisão 60/40 única com 18–20 papéis; o walk-forward de 6 dobras sobre a watchlist de 10 dá 0,551, IC 95% [0,527, 0,576]. O `medidas.py` passou a registrar as duas, e o selo exibe a estrita.

A data de divulgação é **aproximada** — dia 10 rolado para dia útil. O IBGE publica calendário próprio e a data varia. Errar o dia borra um estudo de evento que mede reação no mesmo dia, e isso explicaria um p de 0,5 com efeito real por trás.

O próximo teste é trocar pelas datas reais, não acumular mais amostra.

Como ela está na arquitetura

A camada existe (`obs/surpresa.py` , comando `obs surpresa`), grava as surpresas e estima os betas — mas **não entra no sinal**. `ATIVO = False` , pela mesma disciplina do meta-labeling: nada entra sem passar no teste.

O `obs status` informa o estado e o motivo em uma linha.

O que fica em aberto, e vale mais que o IPCA

Resultado trimestral de empresa tem a propriedade que falta a tudo no projeto: o efeito de surpresa de lucro se manifesta ao longo de **dias a semanas**, não no leilão de abertura. Esse é o horizonte onde custo de transação amortiza — a única via que pode mudar o veredito econômico.

CVM responde (ITR, DFP, FCA), então datas e números realizados são gratuitos. **Falta a expectativa**: o Focus cobre macro, não lucro de empresa individual, e consenso de analistas para resultado trimestral no Brasil não é gratuito. Ou se paga, ou se constrói um modelo de expectativa próprio — mais fraco, mas testável.

Fontes de dados e a conta

Todas verificadas respondendo. O projeto inteiro roda com **zero** de custo recorrente.

Fonte	O que dá	Chave?	Custo
Yahoo Finance	Preços B3 (10 anos), índices, commodities, câmbio, ADRs	não	R\$ 0
BCB Olinda (Focus)	Consenso macro com mediana, desvio e nº de respondentes	não	R\$ 0
BCB SGS	Realizado: IPCA, IGP-M, desocupação, câmbio, Selic, PIB	não	R\$ 0
DBnomics	94 provedores: FED, BLS, ECB, OECD, IMF, Eurostat, BIS, ILO	não	R\$ 0
CVM dados abertos	ITR/DFP: BPA, BPP, DRE, DFC, composição de capital	não	R\$ 0
GDELT 2.0	Notícias globais, 15 min	não	R\$ 0
brapi.dev	Preços e fundamentos B3	sim	R\$ 119,99/mês (Startup) · R\$ 139,99 (Pro)

O brapi deixou de ser necessário. Sua cota gratuita não cobria 10 papéis; o Yahoo entregou **24.908 cotações, 10 anos**, sem chave.

DBnomics resolve o macro multinacional que o FRED bloqueava por exigir chave e o World Bank só tinha anual. Verificado: CPI americano do BLS com 937 observações mensais desde 1947, HICP da zona do euro, indicador antecedente do OECD. Ressalva: alguns espelhos ficam defasados — serve para histórico, não para acompanhamento ao vivo.

O que custa

O scorer por LLM, a única peça paga que vale a pena. Premissa: ~1.500 tokens de entrada e ~200 de saída por artigo.

Modelo	Por artigo	500/dia	2.000/dia
Haiku 4.5	US\$ 0,0025	R\$ 194/mês	R\$ 777/mês
Sonnet 5	US\$ 0,0050	R\$ 388/mês	R\$ 1.554/mês
Opus 5	US\$ 0,0125	R\$ 971/mês	R\$ 3.885/mês

Mas não é assim que se deve pagar. A destilação — o LLM rotula uma vez, um encoder pequeno serve o resto — muda a ordem de grandeza:

	Custo
3.000 artigos com Haiku	R\$ 39, uma vez
10.000 artigos com Haiku	R\$ 130, uma vez
10.000 com Sonnet 5	R\$ 259, uma vez

A conta de fechar a maior lacuna

Para responder a pergunta aberta desde o início — *o canal de notícias tem sinal?* — bastam alguns milhares de artigos rotulados:

destilação com Haiku, 3.000 artigos	R\$	39	(uma vez)
todo o resto	R\$	0	
	R\$	39	

O único item sem alternativa gratuita

Consenso de lucro por empresa, que destrava o PEAD. LSEG/Refinitiv, FactSet e Bloomberg trabalham com cotação comercial sob contrato, sem tabela pública — **não foi possível apurar o preço**. É a ordem de grandeza mais cara da lista e a única peça do projeto sem substituto conhecido.

Indicadores contábeis — quais ajudam

A CVM entrega de graça todas as linhas brutas (BPA, BPP, DRE, DFC, composição de capital, de 2023 a 2026), então qualquer razão é calculável. A pergunta não é disponibilidade — é **quais importam**.

Fundamentos são trimestrais e lentos: não preveem direção diária. Mas preveem **volatilidade**, que é o canal forte.

Camada 1 — alimentam a cabeça que funciona

Indicador	Por quê
Dívida líquida/EBITDA , alavancagem	Alavancagem amplifica a volatilidade da ação — relação estrutural, não empírica: a ação de empresa endividada é uma opção sobre o ativo
Valor de mercado	Tamanho é o melhor predictor conhecido de volatilidade
Free float	Float baixo → mesma notícia move mais
Margem EBITDA / líquida	Margem fina = alavancagem operacional = resultado mais sensível

Camada 2 — consertam um defeito real do scorer

O `score_llm` pede ao modelo julgar a magnitude *"relativa ao tamanho da empresa"*, e o próprio prompt diz: *"R\$ 1 bi é grande para uma small cap e irrelevante para uma de R\$ 600 bi"*.

Só que o LLM não recebe o tamanho. Nem a alavancagem. Ele chuta.

Alimentar valor de mercado, dívida líquida/EBITDA e free float no prompt transforma palpite em cálculo. Empresa a 4× de alavancagem reage muito mais a notícia ruim que uma a 0,5× — e hoje o sistema trata as duas igual.

Camada 3 — direção, prior baixo

P/L, P/VP, EV/EBITDA, PSR e PEG são o fator **valor**. ROE, ROIC e margens são o fator **qualidade**. Ambos miram direção, que é onde tudo falhou. Com 10 papéis não há poder para testar nenhum dos dois — ficam para depois do universo maior.

O que falta no glossário e importa mais

Volume financeiro médio diário. Define o universo investível, prevê o custo de transação — a barreira que matou toda chance de retorno neste projeto — e filtra papel onde o sinal não é executável.

A recomendação: use fundamentos para **volatilidade e magnitude de notícia**, não para direção. Mesma conclusão a que a investigação chegou por outras rotas.

Defeitos encontrados rodando contra dados reais

Todos apareceram ao executar, nenhum ao revisar código. Valem registro porque reaparecem em qualquer reimplementação.

Sintoma	Causa raiz
Skill de Brier negativo dentro da amostra — impossível para isotônica, já que a taxa-base constante é solução monótona viável	<code>predict</code> interpolava entre bordas direitas de bloco, e valores de <code>z</code> duplicados caíam em blocos diferentes, deixando o ajuste sem ser função de <code>x</code> . Correção: agregar duplicatas antes da PAVA e emitir dois nós por bloco
IC do Brent de 0,19 — alto demais para previsão de gap	A barra diária do Brent roda 01:00 → 00:59 BRT e engloba o pregão inteiro da B3 . Era correlação contemporânea, não previsão
Gap do Ibovespa com desvio de 4,48%	O <code>open</code> do índice é praticamente o <code>close</code> anterior (mediana de $ \text{gap} = 0,001\%$) — índice não tem leilão de abertura. Mais uma linha com <code>open = 0</code> . Ação individual tem gap real
Energia "significativa" com $t = 0,83$	Erro-padrão ingênuo tratando pares (ação, dia) como independentes. Corrigido com Fama-MacBeth
Notícia da Vale casando com matéria sobre bots	O alias <code>VALE</code> em minúscula casa com a palavra comum "vale". Correção: código de papel casa com caixa ; aliases ambíguos barrados

Sintoma	Causa raiz
<code>MISSING_TOKEN</code> do brapi no 2º lote, OK no 1º	Não é falta de autenticação nem limite de lote: é cota de símbolos por janela. A mensagem engana e faz procurar problema de auth
Metade dos tickers sem notícia	GDELT responde 429 pedindo 1 requisição a cada 5 s . Com 2,5 s metade volta vazia, e a mensagem de throttle em texto puro aparecia como "json inválido"
<code>CELULOSE</code> no top-4 de Ambev, Bradesco e Gerdau	Usei <code>WOOD</code> , que é um ETF de ações de madeira/papel, não futuro de celulose. Carregava beta global de bolsa e contaminava toda cadeia
Remover o driver do código não mudou nada	<code>fit_exposures</code> lia todos os drivers do banco, ignorando o registro. Corrigido com filtro por registro e <code>purge_unregistered()</code>
"juros sobre o capital próprio" pontuava 0, mas "JCP" pontuava	Scorer por token não vê expressão de várias palavras. A mesma notícia valia coisas diferentes conforme o jornal abreviasse
Cifra "R\$ 3,8 bi" virando <code>8e9</code>	<code>norm()</code> apaga a vírgula decimal antes do regex. Extrair cifra do texto cru
<code>OverflowError</code> no SQLite	SimHash de 64 bits estoura o <code>INTEGER</code> signed. Usar 63

O padrão comum: **quanto mais limpa a janela temporal, mais fraco o sinal**. Todo IC animador desta investigação veio de contaminação de horizonte ou de erro-padrão inflado.

Ideias para melhorar a previsão

Ordenadas por ganho esperado. As três primeiras são onde está o retorno; o resto é refinamento.

1. Horizonte de 5 a 20 pregões, não D+1

A única ideia que ataca a barreira de custo em vez do IC. Hoje o sinal vive no leilão de abertura — a janela mais cara do pregão — e some até o fechamento. Em horizonte maior o custo amortiza sobre mais retorno, em troca de IC menor.

Custo de 15 pontos-base sobre um giro diário consome 6 pontos-base de vantagem. Sobre um giro mensal, a mesma vantagem acumulada por 20 pregões pode sobrar. **É a única via que muda a aritmética**, e ainda não foi testada.

2. Corpo da notícia + extrator por LLM

Hoje o scorer lê só manchete. Título diz *o que* aconteceu; corpo diz *quanto*. Materialidade é metade do sinal e está sendo chutada por regex.

O LLM preenche um schema — tickers, tipo de evento, direção, materialidade, se é rumor — e esses campos viram features de um modelo estatístico. O LLM é sensor, nunca oráculo.

Armadilha: um modelo treinado até hoje **sabe** o que aconteceu com o papel. Em backtest histórico isso vaza futuro. Mitigação: pedir só fatos presentes no texto, sem data, sem desfecho, e validar em janela posterior ao cutoff.

3. Roteamento de notícias pela cadeia de afetação

O uso de maior valor da cadeia, e o que você descreveu sem perceber que era o principal. A cadeia diz que PETR4 é 49% Brent — então notícia sobre OPEP, estoques americanos ou corte saudita vira sinal para PETR4 e PRIO3 **sem que nenhuma seja citada no texto**.

Hoje você tem 23 scores em 156 artigos porque um papel só reage a matéria que escreve o nome dele. O roteamento multiplica a contagem de eventos — que é o gargalo do canal com maior potencial não medido.

Ressalva honesta: roteamento aumenta **amplitude**, com efeito ambíguo sobre o IC por evento. Notícia de petróleo afeta PETR4 de forma menos específica que notícia da Petrobras.

4. Universo de 150 a 300 papéis

Não melhora o IC. Melhora três outras coisas, e todas importam:

1. **Poder estatístico** — com 10 papéis e um ano, 22% de chance de detectar um IC de 0,03 que seja real. Com 300, meses.
2. **Amplitude** — $IR \approx IC \times \sqrt{\text{amplitude}}$, e o resíduo transversal já remove o fator comum que fazia 10 blue chips valerem 1,7 apostas.
3. **Small caps** — o único jeito de ter papéis do lado lento da fila, onde lead-lag e sub-reação a notícia de fato vivem.

5. Surpresa contra consenso em eventos agendados

Preço reage a surpresa, não a notícia. Balanço que confirma o consenso move zero. Hoje o sistema não tem consenso — trata toda notícia como nova.

Para evento agendado (resultado trimestral, Copom, IPCA) existe expectativa publicada. A diferença entre realizado e esperado é o sinal, e é muito mais limpa que polaridade de texto.

6. Meta-labeling: prever SE opera, não a direção

Em vez de um modelo que diz "vai subir", dois modelos: um dá a direção, outro estima a probabilidade de aquela direção estar certa, e você só age quando o segundo é confiante.

Isso converte IC baixo em taxa de acerto alta **sobre um subconjunto pequeno** — que é exatamente o regime em que custo de transação é sobrevivível, porque você opera pouco. Técnica de López de Prado, e encaixa direto no desenho atual de portas dos alarmes.

7. Lead-lag por elo econômico, não por correlação

A versão por correlação de pares está **empiricamente refutada** neste universo. A versão estruturada continua em aberto: movimento do cliente prevendo retorno do fornecedor, com elos lidos de documentos, horizonte de semanas e universo que inclua small caps.

Exige identificar quem vende para quem — não varrer pares. É um projeto próprio, não um ajuste.

8. Pesos de fonte aprendidos

Barato e ainda não feito. Hoje os pesos de veículo são palpite escrito à mão. A versão correta mede se aquela fonte **antecede** o movimento — e por par (veículo, driver), porque fonte boa para petróleo não é fonte boa para varejo.

O que eu não recomendo

Ideia	Por quê
FinBERT	Com LLM disponível, é passo intermediário sem destino
Mais drivers macro	Medido: 14 drivers dão pior que 4. Diluição
Detector de regime por Markov	Feature de contexto, não de direção
Commodities e ouro como sinal	Medido e reprovado no teste rigoroso
Árvore sintática	Já cortada, corretamente

O alvo errado

Esta é a conclusão central da investigação, e ela é desconfortável.

O que é robusto é sobre magnitude, não sobre direção.

Alvo	Sinal medido
Direção em D+1	IC 0,081
Volatilidade	IC 0,303

Três rotas independentes chegaram aí: a cabeça de direção, a de volatilidade, e as anomalias famosas testadas nos dados do projeto (onde só persistência de volatilidade sobreviveu, com $t = +11,34$ contra $+0,74$ do momento).

O projeto foi construído para prever **direção**, porque era isso que o TCC de 2013 propunha. Tudo que medimos diz que direção é fraca e magnitude é forte.

O que isso significa para o produto

Com o que está medido, o entregável defensável é um **observatório de agitação**:

"PETR4 tem 3× a chance normal de ter um dia agitado amanhã, e estas são as notícias e os drivers por trás."

"Vai subir 2%" não é.

Quanto a direção pode chegar

A pergunta voltou de cinco formas e convergiu nas cinco:

Configuração	Acertos em 100
Antes da cadeia de drivers	50,8
Com exposição cambial	52,6
Implementando tudo que resta	52,9 (esperado)
Cenário otimista (20% de chance)	53,3

O ganho de **tudo** o que falta implementar é de **+0,3 acerto em 100**. E há 35% de chance de ser zero.

Por que 70% não existe

Acerto de 70% exige IC de **0,588** — 7,3× o que medimos. Fundos quantitativos de primeira linha operam entre 0,05 e 0,10; o projeto está em 0,08. A distância não é lacuna de engenharia: é a diferença entre ter um sinal e saber o futuro.

Dá para trocar frequência por precisão, operando só nos sinais extremos:

Acerto alvo	Eventos/ano (300 papéis)
55%	14.300
60%	630
65%	4,6
70%	0,004 — uma vez a cada 273 anos

Os dois primeiros são sistemas. 70% não acontece. (A tabela assume normalidade na cauda, que é onde a hipótese menos vale — leia 60% como teto otimista.)

Onde 70%+ existe de verdade

Mudando o alvo, não o modelo:

Pergunta	Acerto alcançável
Amanhã será dia de volatilidade alta?	70-80%
Esta notícia é material para este papel?	85-90%

Pergunta	Acerto alcançável
Direção da ação em D+1	52–53%

As duas primeiras são alcançáveis com o que já existe. A diferença é que nenhuma delas diz **para onde** o papel vai — e é justamente por isso que são previsíveis.

Uma ressalva sobre esta seção

Os números são medidos. A conclusão de que o projeto deveria **mudar de alvo** é interpretação, e cabe discordância: se o objetivo é o TCC, defender direção com rigor e **mostrar que ela é fraca** é trabalho perfeitamente válido — talvez melhor que trocar de alvo no meio.

Roteiro

Cada fase tem critério de parada. Se o critério falhar, a fase seguinte não compensa — e esse é um resultado válido, não um fracasso.

Fase	O que fazer	Critério de parada
0. Destravar	Token gratuito do brapi; universo de 150–300 papéis por liquidez	Histórico suficiente para calibrar com retorno real
1. Horizonte	Repetir a exposição cambial em 5 e 20 pregões	Se o IC líquido de custo não for positivo em nenhum horizonte, a via de retorno financeiro fecha
2. Corpo + LLM	Baixar corpo do artigo; <code>score_11m</code> com schema	IC do canal de notícias medido pela primeira vez. Se ficar indistinguível de zero, o projeto é de pesquisa, não de sinal
3. Roteamento	Ligar a cadeia ao <code>ingest</code> : cada papel consulta por seus drivers principais	Contagem de eventos sobe de ~23 para centenas. Medir se o IC por evento se mantém
4. Pesos aprendidos	<code>fit-source-weights</code> por par (veículo, driver)	Ganho incremental de IC sobre pesos manuais
5. Meta-labeling	CONSTRUÍDO E REPROVADO: $t = 1,53$, sem monotonia, AUC 0,517. Porta desligada	Refazer só com features que identifiquem regime, exigindo $t > 2$ com monotonia

O que manter em mente

A fase 1 é a única que pode mudar o veredito econômico. As fases 2 a 5 melhoram o IC; nenhuma delas atravessa a barreira de 6 contra 15 pontos-base sozinha. Só horizonte maior muda a aritmética — e o meta-labeling, que era a outra aposta nesse sentido, já foi testado e reprovado.

O canal de notícias é o maior risco e o maior potencial. Toda a estrutura de texto — cluster, relevância, novidade, léxico — foi verificada funcionalmente, mas nunca contra retorno realizado. Há chance real de que não adicione nada ao que o preço já diz.

Como TCC, o trabalho já se sustenta. Um projeto que mede 52,6 acertos em 100 com nula por permutação, walk-forward com embargo e três medições próprias invalidadas e corrigidas vale mais que um que anuncia 87% sem validação. O trabalho de 2013 anunciava 87% e 99%, mas aquilo media se o classificador separava texto econômico de não-econômico — não se previa preço.

Ressalva final

Este é um observatório de pesquisa. **Não é recomendação de investimento**, e os números aqui descrevem detectabilidade estatística, não retorno esperado de carteira.

O efeito de reversão cambial apareceu de forma consistente em três medições independentes, mas a disciplina honesta é tratá-lo como hipótese a confirmar em dado novo — muitos testes foram acumulados nesta investigação.